

Offline measuring · results

HDI-Demo · 2026-10-01 · 3 runs

What we measured: 50 mock claims (10 clean, 40 with a known trap) sent through the service. Each claim either goes through automatically or goes to a person, and each result is checked against the answer key.


Latest run (3 · better prompt):



Since the baseline: automatic and correct went from 16 to 35. Automatic but wrong went from 5 to 2.

- [1. What happened to the 50 claims, per run](#)
- [2. Per field, per run](#)
- [3. Per kind of claim](#)
- [4. Where the AI model is needed: choosing between candidates](#)
- [5. Every claim the AI model got wrong](#)
- [6. Runs and limits](#)
- [7. Appendix: full texts of the missed claims](#)

1 · What happened to the 50 claims, per run




2 · Per field, per run

field the AI model got right	1 · baseline	2 · date fix	3 · better prompt
policy number	43 of 50	43 of 50	50 of 50
incident date	32 of 50	48 of 50	46 of 50
amount	47 of 50	47 of 50	46 of 50
licence plate	47 of 50	47 of 50	49 of 50

3 · Per kind of claim

One row per kind of claim, one square per claim. A claim keeps its position in every run.



4 · Where the AI model is needed: choosing between candidates (3 · better prompt)

Plain pattern search finds every date and amount in a claim. When a claim contains more than one, only the AI model can choose the right one.

- Dates: 7 claims had more than one date, and the AI model chose right in 7.
- Amounts: 9 claims had more than one amount, and the AI model chose right in 7.

5 · Every claim the AI model got wrong (3 · better prompt: 9)

The mistake isn't always in the field the claim was built to test.

What the claim tests	Field wrong	AI model said	Answer key	What happened
<u>Two dates: report date (25.06.) one day after the incident, written first; context only</u>	amount	690.00	690.50	to a person, rightly
<u>Two amounts: the car's value (12.500 €) comes first and is the larger sum</u>	amount	(nothing)	4980.00	to a person, rightly
<u>Two amounts: a rejected quote (3.150,00 €) comes first; only context says which one is claimed</u>	amount	(nothing)	2480.00	to a person, rightly
<u>A correction in the text: date corrected mid-call, in a clerk's phone note (12.03. → 13.03.)</u>	amount	(nothing)	480.00	to a person, rightly
<u>Unusual date form: date written out ("3. März 2026")</u>	incident date	(nothing)	2026-03-03	to a person, rightly
<u>Unusual date form: date without a year ("17.4."); the year comes from the letter date</u>	incident date	(nothing)	2026-04-17	to a person, rightly

What the claim tests	Field wrong	AI model said	Answer key	What happened
<u>Unusual date form: relative date ("gestern"); anchor = the email's sent date (09.06.2026)</u>	incident date	2026-06-09	2026-06-08	automatic, wrong
<u>Unusual date form: relative date ("letzten Freitag"); anchor = the letter date, itself written out (Mon 13 July → Fri 10 July)</u>	incident date	(nothing)	2026-07-10	to a person, rightly
<u>Forwarded thread: old plate (W-39152A) twice in two quoted messages, ">" style</u>	licence plate	W-39152A	W-70284E	automatic, wrong

6 · Runs and limits

run	what changed in this run	code (commit)	AI model	mock claims
1 · baseline	the service as first built (dates requested in year-first format; short first-draft prompt)	c1c6376	qwen3.5:4b	50
2 · date fix	the AI model copies each date exactly as the claim writes it (e.g. 28.04.2026); our code converts it	e7d9b76	qwen3.5:4b	50
3 · better prompt	the prompt defines the four fields and their formats (policy number, plate, German amounts)	20b964b	qwen3.5:4b	50

50 mock claims, written for this demo: 10 clean, and 8 kinds of messiness with 5 claims each. For each kind, the results show whether the approach handles it. Kinds not in the set remain untested. The set is too small and too artificial to promise an error rate on real claims; that would need real (anonymized) claims at a much larger scale. The prompt of the last run was revised after seeing the first run's results on this same set (see README).

Appendix · full texts of the missed claims (3 · better prompt)

Two dates: report date (25.06.) one day after the incident, written first; context only

to a person, rightly claim k1-05 in eval/mock_claims.yaml

Betreff: Schriftliche Nachmeldung

Sehr geehrte Damen und Herren,

wie am Telefon besprochen, reiche ich meine Schadensmeldung schriftlich nach. Ich habe den Schaden bereits am 25.06.2026 bei Ihrer Hotline gemeldet. Passiert ist es am Tag davor, am 24.06.2026: In der Waschstraße in der Triester Straße wurde der Heckscheibenwischer abgerissen und die Heckklappe zerkratzt.

Kennzeichen W-5618 GV, Polizze VK-842716-A. Die Reparatur kostet 690,50 €.

Mit freundlichen Grüßen
Barbara Koller

field	AI model	answer key	
policy number	VK-842716-A	VK-842716-A	✓
incident date	2026-06-24	2026-06-24	✓
amount	690.00	690.50	✗
licence plate	W-5618 GV	W-5618GV	✓

Proxy checks that flagged: amount: 690.00 not found among the amounts in the claim text

Two amounts: the car's value (12.500 €) comes first and is the larger sum

to a person, rightly claim k2-02 in eval/mock_claims.yaml

Betreff: Hagelschaden Perchtoldsdorf

Guten Tag,

mein Auto ist laut Kaufvertrag rund 12.500 € wert, deshalb war ich froh, dass es kein Totalschaden ist: Am 14.07.2026 hat ein Hagelsturm in Perchtoldsdorf Motorhaube, Dach und Kofferraumdeckel verbeult. Die Werkstatt schätzt die Reparatur auf 4.980 €.

Kennzeichen MD-5027K, Polizzi VK-163482-C.

Beste Grüße
Wolfgang Aigner

field	AI model	answer key	
policy number	VK-163482-C	VK-163482-C	✓
incident date	2026-07-14	2026-07-14	✓
amount	(nothing)	4980.00	✗
licence plate	MD-5027K	MD-5027K	✓

Proxy checks that flagged: amount: missing

Two amounts: a rejected quote (3.150,00 €) comes first; only context says which one is claimed

to a person, rightly claim k2-03 in eval/mock_claims.yaml

Sehr geehrte Damen und Herren,

am 19.03.2026 habe ich beim Vorbeifahren an einer Baustellenabspernung in der Gudrunstraße den rechten Außenspiegel und den Kotflügel beschädigt. Der erste Kostenvoranschlag der Vertragswerkstatt über 3.150,00 € war mir zu hoch. Eine zweite Werkstatt macht es um 2.480,00 €, dort lasse ich die Reparatur durchführen.

Kennzeichen: W-90213C
Polizzennummer: VK-706951-A

Mit freundlichen Grüßen
Nicole Haas

field	AI model	answer key	
policy number	VK-706951-A	VK-706951-A	✓
incident date	2026-03-19	2026-03-19	✓
amount	(nothing)	2480.00	✗
licence plate	W-90213C	W-90213C	✓

Proxy checks that flagged: amount: missing

A correction in the text: date corrected mid-call, in a clerk's phone note (12.03. → 13.03.)

to a person, rightly claim k4-01 in eval/mock_claims.yaml

[Eingangskanal: Telefon - Notiz Schadenservice]

Anruferin: Sandra Leitner, Polizze VK-490263-C, Kfz W-35816V.
Kundin meldet Parkschaden: Auf dem Parkplatz beim Einkaufszentrum ist ein Einkaufswagen gegen ihre Fahrtür gerollt. Schadendatum lt. Kundin 12.03.2026 - korrigiert sich im Gespräch: Es war der 13.03.2026, sie hatte sich im Kalender vertan. Werkstatt veranschlagt 480,00 €. Kundin reicht Fotos per Mail nach.

field	AI model	answer key	
policy number	VK-490263-C	VK-490263-C	✓
incident date	2026-03-13	2026-03-13	✓
amount	(nothing)	480.00	✗
licence plate	W-35816V	W-35816V	✓

Proxy checks that flagged: amount: missing

Unusual date form: date written out ("3. März 2026")

to a person, rightly claim k6-01 in eval/mock_claims.yaml

Sehr geehrte Damen und Herren,

am 3. März 2026 bin ich auf Schneematsch in der Grinzinger Straße ins Rutschen gekommen und gegen einen Hydranten gefahren. Beschädigt sind Stoßstange und Kühler.

Kennzeichen W-16287F, Polizzennummer VK-285730-A. Die Reparatur kostet laut Werkstatt 2.890,00 €.

Mit freundlichen Grüßen
Renate Frank

field	AI model	answer key	
policy number	VK-285730-A	VK-285730-A	✓
incident date	(nothing)	2026-03-03	✗
amount	2890.00	2890.00	✓
licence plate	W-16287F	W-16287F	✓

Proxy checks that flagged: incident date: the AI model's value '3. März 2026' doesn't fit this field's type

Unusual date form: date without a year ("17.4."); the year comes from the letter date

to a person, rightly claim k6-02 in eval/mock_claims.yaml

Wien, 22.04.2026

Sehr geehrte Damen und Herren,

am 17.4. habe ich beim Rückwärtsausparken vor der Schule in der Schopenhauerstraße ein Verkehrszeichen erwischt.
Der hintere Stoßfänger ist gebrochen.

Kennzeichen W-60718B, Polizze VK-517042-C. Kosten laut Werkstatt 1.045,00 €.

Mit freundlichen Grüßen
Bernhard Hofer

field	AI model	answer key	
policy number	VK-517042-C	VK-517042-C	✓
incident date	(nothing)	2026-04-17	✗
amount	1045.00	1045.00	✓
licence plate	W-60718B	W-60718B	✓

Proxy checks that flagged: incident date: the AI model's value '17.4.' doesn't fit this field's type

Unusual date form: relative date ("gestern"); anchor = the email's sent date (09.06.2026)

automatic, wrong claim k6-03 in eval/mock_claims.yaml

Von: Simone Wolf
Gesendet: 09.06.2026 08:14
Betreff: Außenspiegel

Guten Morgen,

gestern Abend hat mir jemand in der Kurzparkzone in der Burggasse den linken Außenspiegel abgefahren. Kennzeichen W-43790Y, Polizze VK-360418-B. Der neue Spiegel kostet 455,00 €.

Danke, Simone Wolf

field	AI model	answer key	
policy number	VK-360418-B	VK-360418-B	✓
incident date	2026-06-09	2026-06-08	✗
amount	455.00	455.00	✓
licence plate	W-43790Y	W-43790Y	✓

Proxy checks that flagged: none

Unusual date form: relative date ("letzten Freitag"); anchor = the letter date, itself written out (Mon 13 July → Fri 10 July)

to a person, rightly claim k6-04 in eval/mock_claims.yaml

Wien, am 13. Juli 2026

Sehr geehrte Damen und Herren,

letzten Freitag bin ich auf dem Heimweg auf der Erdberger Lände durch ein tiefes Schlagloch gefahren. Felge und Reifen vorne rechts sind hinüber.

Mein Kennzeichen: W-92365T
Polizzenummer: VK-679214-D
Kosten laut Werkstatt: 720,00 €

Mit freundlichen Grüßen
Walter Seidl

field	AI model	answer key	
policy number	VK-679214-D	VK-679214-D	✓
incident date	(nothing)	2026-07-10	✗
amount	720.00	720.00	✓
licence plate	W-92365T	W-92365T	✓

Proxy checks that flagged: incident date: the AI model's value 'letzten Freitag' doesn't fit this field's type

Forwarded thread: old plate (W-39152A) twice in two quoted messages, ">" style

automatic, wrong claim k7-03 in eval/mock_claims.yaml

Betreff: AW: AW: Schadensmeldung

Guten Tag,

danke für Ihre Nachfrage. Ich habe im ersten Mail das Kennzeichen meines alten Autos angegeben. Das versicherte Fahrzeug hat das Kennzeichen W-70284E.

Mit freundlichen Grüßen
Lisa Neubauer

Schadenservice schrieb:

> Sehr geehrte Frau Neubauer,
> das angegebene Kennzeichen W-39152A ist unter Ihrer Polizze nicht erfasst. Bitte prüfen Sie Ihre Angaben.
> Mit freundlichen Grüßen
> Ihr Schadenservice
>

> Lisa Neubauer schrieb:
>> Sehr geehrte Damen und Herren,
>> am 20.03.2026 habe ich beim Einparken in der Garage unseres Wohnhauses die Seitenwand gestreift.
>> Kennzeichen W-39152A, Polizze VK-431962-B, Reparatur 1.960,00 €.
>> Mit freundlichen Grüßen
>> Lisa Neubauer

field	AI model	answer key	
policy number	VK-431962-B	VK-431962-B	✓
incident date	2026-03-20	2026-03-20	✓
amount	1960.00	1960.00	✓
licence plate	W-39152A	W-70284E	✗

Proxy checks that flagged: none